FOREST FIRES

Análise de Dados, Regressão Linear e Ridge

Dataset: Forest Fires — UCI Machine Learning Repository
Parque Natural de Montesinho, Portugal

Outubro de 2026

Handout para apresentação em grupo — 7 participantes

Sumário

1 Entendendo o Dataset

2 Investigação Exploratória: o que a variável alvo esconde

3 Preparação e Pré-processamento dos Dados

4 Baseline e Regressão Linear (OLS)

5 Regressão Ridge

6 Avaliação, Comparação e o Modelo em Duas Partes

7 Interpretação dos Resultados e Conclusão

Objetivo: prever a área queimada (ha) em incêndios florestais a partir de variáveis meteorológicas e índices FWI (Fire Weather Index), comparando Regressão Linear com Regressão Ridge (regularização L2). O caminho até a resposta acabou valendo mais que a resposta: o trabalho mostra por que este dataset resiste a qualquer modelo linear, e o que isso ensina sobre preparação de dados.

1. Entendendo o Dataset

Origem e contexto

O dataset **Forest Fires** foi coletado no Parque Natural de Montesinho, nordeste de Portugal, e publicado por Cortez e Morais (2007) no UCI Machine Learning Repository. Reúne **517 ocorrências** de incêndio registradas entre 2000 e 2003, cada uma com as condições meteorológicas do momento e os índices do sistema canadense FWI. Um detalhe do registro vai pesar em toda a análise: a área é anotada com duas casas decimais, de modo que **area = 0 significa área abaixo de 0,01 ha**, e não ausência de fogo.

Variáveis do dataset

Coluna	Tipo	Descrição
X, Y	Inteiro	Coordenadas espaciais na grade do parque (1 a 9)
month	Texto	Mês do ano (jan – dec)
day	Texto	Dia da semana (mon – sun)
FFMC	Decimal	Fine Fuel Moisture Code — umidade dos combustíveis finos
DMC	Decimal	Duff Moisture Code — umidade da camada orgânica do solo
DC	Decimal	Drought Code — seca acumulada no solo profundo
ISI	Decimal	Initial Spread Index — velocidade inicial de propagação
temp	Decimal	Temperatura do ar (°C)
RH	Inteiro	Umidade relativa do ar (%)
wind	Decimal	Velocidade do vento (km/h)
rain	Decimal	Chuva nas últimas 24h (mm/m^2)
area (*)	Decimal	VARIÁVEL ALVO — área queimada (hectares)

(*) variável que queremos prever (alvo / target)

Primeiro olhar sobre os dados

Valores ausentes	Nenhum em nenhuma das 13 colunas.
Variável rain	Mais de 98% dos registros têm rain = 0; variância quase nula, sem poder preditivo.
Sazonalidade	Agosto e setembro concentram 69% das ocorrências; jan, may e nov têm 1 ou 2 registros; apr e dec, 9 cada.
Correlações	Nenhuma variável numérica passa de |0,07| de correlação com log1p(area); os índices FWI são correlacionados entre si, o que justifica testar o Ridge.

2. Investigação Exploratória: o que a variável alvo esconde

Visão geral numérica

Métrica	area (ha)	temp (°C)	RH (%)	wind (km/h)
Mínimo	0,00	2,2	15	0,4
Mediana	0,52	19,3	42	4,0
Média	12,85	18,9	44	4,0
Máximo	1090,84	33,3	100	9,4
Desvio-padrão	63,66	5,8	16	1,8

A tabela já dá o aviso: a média da área (12,85 ha) é 25 vezes a mediana (0,52 ha), com poucos incêndios enormes puxando a média enquanto metade dos registros fica abaixo de meio hectare. A análise exploratória foi atrás desse descompasso e encontrou algo que a transformação logarítmica usual não resolve.

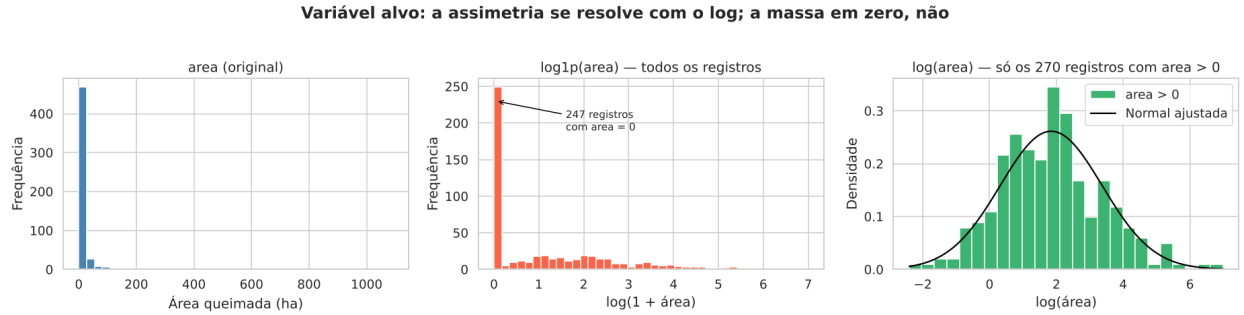


Figura 1 — A variável alvo antes e depois do log. O pico em zero não se move; os valores positivos, isolados, são quase normais.

A transformação resolve a assimetria, mas não o pico

O painel do meio é o que costuma aparecer como "alvo transformado", e ele não se parece com uma normal porque não tem como: **247 dos 517 incêndios (47,8%) têm area exatamente igual a zero**. Uma transformação monotônica leva 247 valores iguais em 247 valores iguais, de modo que nenhum log, raiz ou Box-Cox desloca esse pico. Já o painel da direita isola os 270 registros com área positiva, e aí o log(area) é praticamente normal: skewness de 0,30, teste de Shapiro-Wilk sem rejeitar a normalidade (p ~ 0,24) e Box-Cox escolhendo lambda ~ 0, que é o próprio log.

> [!] O alvo não é apenas assimétrico: é **semicontínuo com inflação de zeros**. Há duas perguntas escondidas numa só variável — o incêndio passou de 0,01 ha? e, se passou, quanto queimou? — e a seção 6 as trata separadamente.

3. Preparação e Pré-processamento dos Dados

Com base na EDA, aplicamos seis transformações para deixar os dados prontos para a regressão:

(1) Transformação log1p(area)
Aplicamos log(1 + area) ao alvo. A transformação estabiliza a escala dos valores positivos (skewness de 12,8 cai para 1,2) e põe o erro em escala multiplicativa, adequada a áreas que vão de 0,1 a 1 000 ha. A massa em zero continua lá e recebe tratamento próprio na seção 6.

(2) Remoção de rain
Descartada por variância quase nula (98,5% dos valores iguais a zero).

(3) Agrupamento dos meses raros
jan, may, nov, apr e dec, todos com menos de 10 registros, viraram a categoria "outros". Uma dummy ajustada em dois pontos é ruído puro: antes do agrupamento, month_dec liderava o ranking de coeficientes do OLS com nove registros.

(4) One-Hot Encoding
month e day viraram colunas binárias, com drop_first=True para evitar a armadilha das dummies. Resultado: 22 preditores.

(5) Divisão treino/teste (80/20)
413 amostras de treino e 104 de teste, com random_state=42. O modelo aprende no treino e é avaliado em dados que nunca viu.

(6) Padronização com StandardScaler
Cada feature centralizada (média 0) e escalada (desvio 1), com o scaler ajustado só no treino. Na validação cruzada ele entra num Pipeline e é reajustado em cada dobra, sem vazamento.

Resultado do pipeline

Etapa	Features	Observação
Dataset original	12 preditores + 1 alvo	13 colunas
Após remoção de rain e agrupamento + OHE	22 preditores	7 dummies de mês, 6 de dia
Após divisão e padronização	22 × 413 treino / 22 × 104 teste	fit no treino, transform no teste

4. Baseline e Regressão Linear (OLS)

Primeiro, a régua: o baseline

Antes de qualquer modelo, registramos o desempenho de prever sempre a média do treino. Todo modelo precisa vencer essa régua; se não vence, as features não estão acrescentando informação. Essa referência faltava na primeira versão do trabalho, e sem ela um R^2 de 0,03 parece "baixo mas positivo" em vez do que é: indistinguível de zero.

O que é a Regressão Linear

A **Regressão Linear Ordinária** (OLS) encontra o hiperplano que minimiza a soma dos quadrados dos resíduos. A solução é analítica, $\mathbf{B = (X'X)^{-1}X'y}$, e exige que X'X seja invertível, o que fica instável quando as features são correlacionadas.

y_pred = b0 + b1·x1 + b2·x2 + ... + bn·xn

y_pred = log(1+area) estimado | b0 = intercepto | bi = coeficientes | xi = features

Resultados obtidos

Modelo	Conjunto	RMSE	MAE	R^2
Baseline (média)	Treino	1,3746	1,1439	0,0000
Baseline (média)	Teste	1,4830	1,2028	-0,0006
OLS	Treino	1,3382	1,0996	0,0523
OLS	Teste	1,4610	1,1736	0,0288

[!] O OLS fica 0,02 de RMSE abaixo do baseline no teste e, como a seção 6 mostra, **acima** dele na validação cruzada. Uma diferença que troca de sinal conforme a avaliação está dentro do ruído.

5. Regressão Ridge

O que é

A **Regressão Ridge** acrescenta à função de custo do OLS uma **penalização L2**, que encolhe os coeficientes em direção a zero e torna o modelo menos sensível à multicolinearidade.

Custo Ridge = Soma dos Quadrados dos Resíduos + α × soma de bi^2

Primeiro termo = OLS (minimiza o erro)
Segundo termo = penalidade (pune coeficientes grandes)
α controla a intensidade da regularização: $\alpha = 0$ é o OLS; alfa tendendo ao infinito zera todos os coeficientes

Como escolhemos o α

Usamos o **RidgeCV** com 200 valores de α entre 0,001 e 10 000 (escala logarítmica) e validação cruzada de 10 dobras. O α escolhido foi **10 000, o teto da grade**: a validação cruzada pediu a maior penalização disponível e teria pedido mais se houvesse.

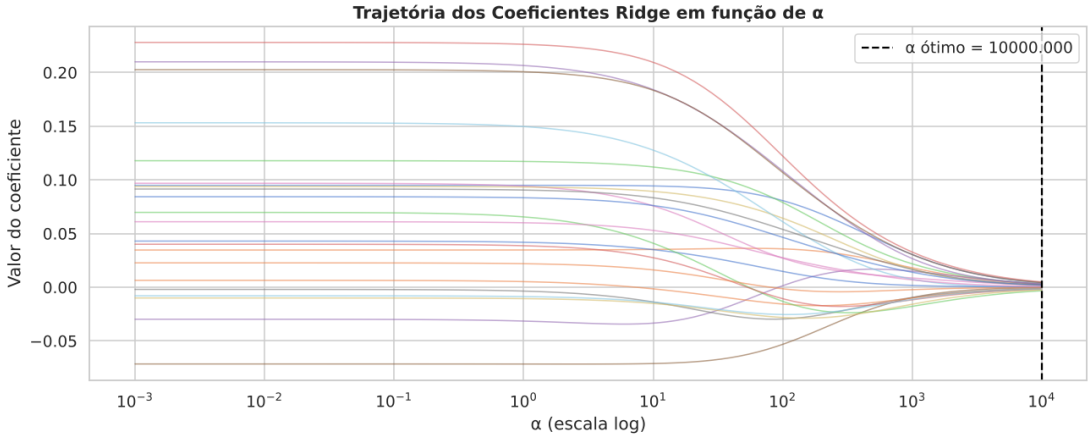


Figura 2 — Trajetória dos 22 coeficientes conforme α cresce. Cada linha é uma feature; a tracejada marca o α escolhido, onde todas já convergiram para zero.

A figura 2 é a peça central da seção. Num dataset com sinal, a validação cruzada para em algum ponto da região em que as curvas estão dobrando, onde o ruído já foi amortecido e os efeitos reais sobrevivem. Aqui ela caminhou até a parede direita. As linhas que se cruzam no meio do caminho mostram outra coisa: a ordem de "importância" das features muda conforme o α, de modo que não existe uma resposta única para qual variável pesa mais.

[*] **Resultados:** RMSE 1,3721 / MAE 1,1420 / R^2 0,0037 no treino; RMSE 1,4812 / MAE 1,2018 / R^2 0,0018 no teste. Com α = 10 000, as previsões no teste têm desvio-padrão de **0,014**, contra **1,49** do alvo: o modelo prevê, na prática, a média. É o que a regularização deve fazer quando as features são ruído.

6. Avaliação, Comparação e o Modelo em Duas Partes

Métricas utilizadas

RMSE	Raiz do erro quadrático médio. Penaliza mais os erros grandes; mesma unidade do alvo (log_area).
MAE	Erro absoluto médio. Mais robusto a valores extremos.
R^2	Proporção da variância explicada. R^2 = 0 equivale a prever a média; negativo é pior que a média. Sob validação cruzada, um modelo sem sinal fica levemente negativo, porque a média de cada dobra de treino difere da média da dobra de teste.

Comparativo geral

Modelo	RMSE Treino	RMSE Teste	MAE Teste	R^2 Teste	CV RMSE (10-fold)
Baseline (média)	1,3746	1,4830	1,2028	-0,0006	1,3878 ± 0,1735
Linear (OLS)	1,3382	1,4610	1,1736	0,0288	1,4000 ± 0,1577
Ridge ($\alpha = 10^4$)	1,3721	1,4812	1,2018	0,0018	1,3869 ± 0,1729

Os três modelos ficam colados. No holdout o OLS aparece à frente; na validação cruzada, que usa os 517 registros e é a estimativa mais confiável, o Ridge empata com o baseline na terceira casa decimal e o OLS fica atrás dos dois. Quando duas avaliações honestas invertem a ordem, a diferença entre os modelos é ruído.

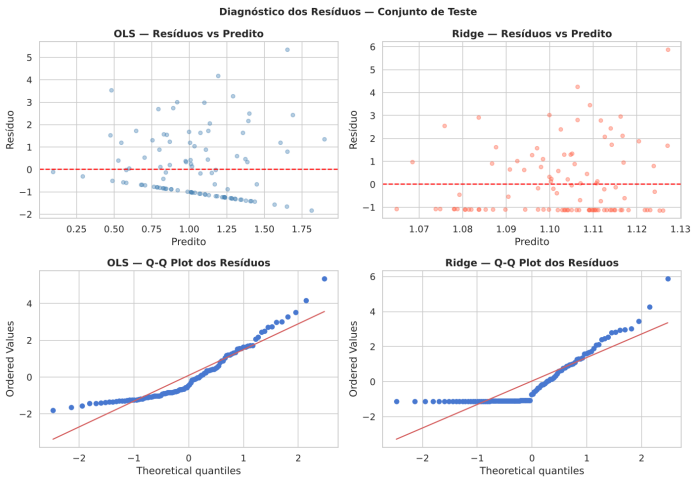


Figura 3 — Resíduos no conjunto de teste. A faixa horizontal em torno de -1 são os incêndios com area = 0.

Diagnóstico dos resíduos

Como o Ridge prevê um valor quase constante, o gráfico de resíduos reproduz o próprio alvo: uma faixa em torno de -1 (os incêndios com area = 0) e uma nuvem acima (os positivos). A "heterocedasticidade" e a cauda do Q-Q plot são a inflação de zeros reaparecendo nos resíduos, não uma violação leve de pressuposto.

6. O modelo em duas partes (hurdle)

A seção 2 mostrou que o problema é a inflação de zeros. A forma clássica de modelar um alvo assim é dividi-lo em duas etapas: uma **classificação** (regressão logística) para "o incêndio passou de 0,01 ha?", e uma **regressão** em log(area) só para os 270 que passaram, onde o alvo é quase normal. Se as variáveis meteorológicas tivessem algum sinal, ele apareceria em pelo menos uma das etapas. Ambas foram avaliadas com previsões fora da dobra (10-fold).

Etapa	Modelo	Métrica	Resultado	Referência
1 — passou de 0,01 ha?	Logística (C = 0,1)	AUC	0,534	0,500 = sorteio
1 — passou de 0,01 ha?	Logística (C = 0,1)	Acurácia	0,542	0,522 = classe majoritária
2 — quanto queimou?	Ridge α = 1 / 10 / 100	RMSE	1,571 / 1,560 / 1,547	1,527 = prever a média
2 — quanto queimou?	Ridge α = 1 / 10 / 100	R^2	-0,063 / -0,048 / -0,031	0 = prever a média

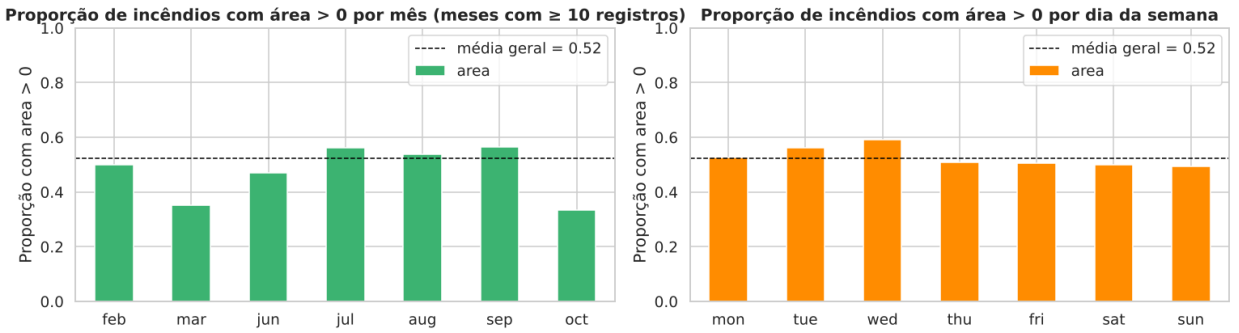


Figura 4 — Proporção de incêndios com área mensurável por mês e por dia da semana. Em nenhum recorte a proporção se afasta muito dos 52% gerais.

Nenhuma das etapas encontra sinal. A classificação fica no nível do sorteio, a regressão nos positivos perde para a média em todos os α testados (os três valores estão lá justamente para mostrar que o α não muda o resultado), e a proporção de incêndios com área mensurável gira em torno de 50% em todo mês e em todo dia da semana. Março e outubro ficam um pouco abaixo, com 35% e 33%, o que é consistente com fogos de primavera e outono serem menores, mas é uma diferença de poucos pontos em amostras pequenas.

[*] O modelo em duas partes é a abordagem estatisticamente correta para este alvo, e justamente por isso o resultado nulo dele é informativo: as variáveis descrevem as condições no momento da ignição, e a área final depende do que não está na tabela.

7. Interpretação dos Resultados e Conclusão

Por que os coeficientes não devem ser interpretados

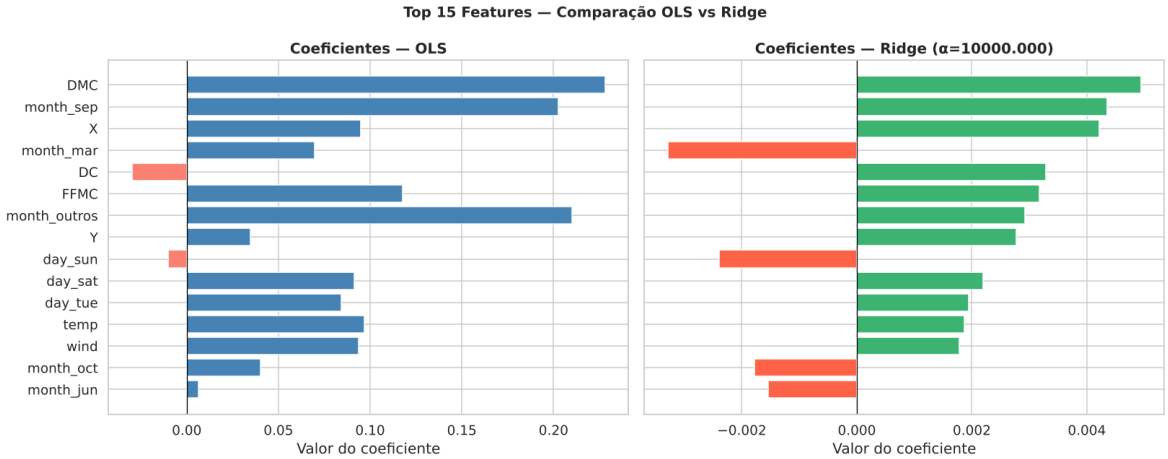


Figura 5 — Top 15 coeficientes. Repare na escala: os do Ridge são de 20 a 50 vezes menores, e DC troca de sinal entre os painéis.

No OLS os maiores coeficientes são DMC, month_outros e month_sep, com DC negativo. No Ridge todos ficam abaixo de 0,005 e DC passa a positivo. Variáveis que a intuição colocaria à frente, como temperatura, ISI e umidade relativa, têm correlação abaixo de 0,1 com o alvo e não se destacam em nenhum dos dois modelos. Quando a ordem e o sinal mudam tanto com a regularização, os coeficientes não estão medindo efeito; estão medindo ruído de amostragem. Atribuir um efeito a "dias mais quentes" ou "mais seca" seria ler o ruído como se fosse sinal.

7. Conclusão

OLS vs Ridge

Critério	OLS	Ridge
Regularização	Nenhuma	L2 (penaliza bi^2)
Multicolinearidade	Problemático	Robusto
Risco de overfitting	Maior	Menor
Validação cruzada	Pior que o baseline	Empata com o baseline
Escolha neste estudo	—	(*) Preferível, por margem pequena

Conclusão

1. A transformação logarítmica está correta, mas resolve só metade do problema: normaliza os valores positivos e não tem como tocar na massa de 47,8% de zeros. O alvo é semicontínuo, e o tratamento adequado é o modelo em duas partes.

2. Mesmo com esse tratamento, as variáveis meteorológicas e os índices FWI não explicam nem **se** o incêndio ultrapassa 0,01 ha nem **quanto** ele queima quando ultrapassa. O melhor modelo linear é, na prática, a média, e a literatura desde Cortez e Morais (2007) encontra o mesmo com modelos não lineares.

3. Entre OLS e Ridge, o Ridge é preferível por não piorar o baseline e por manter os coeficientes pequenos e estáveis, mas a diferença é marginal.

4. O ganho real viria de dados que não estão na tabela: tempo até o início do combate, tipo de vegetação, declividade, e um alvo que separasse área medida de área abaixo do limiar.

Próximos passos sugeridos

- Buscar variáveis de resposta ao incêndio (tempo de combate, meios empregados) e de terreno (vegetação, declividade)
- Modelos não lineares (Random Forest, Gradient Boosting) dentro da estrutura em duas partes, para confirmar que o limite é dos dados e não do modelo
- Lasso e Elastic Net, que zerariam explicitamente as features sem sinal
- Análise espacial das coordenadas X e Y, única dimensão do dataset ainda pouco explorada

Notebook completo: analise_forestfires_v2.ipynb | Dataset: forestfires.csv — UCI Machine Learning Repository